

刘雅秀

电话: 13931198068 (微信同号) | 邮箱: sylvia3337@163.com | 2027 届



个人优势

- 技术背景, 具大模型微调、Infra、Agent 科研经验; AI Agent / LLM 评测 / 电商支付经验, 0-1 项目与跨团队推进经验扎实, 把技术拆解为产品方案的能力
- AI Native, 个人主页: <https://sarbr333.github.io/portfolio/>, 能从用户痛点、业务指标、技术约束出发, 完成需求定义、链路设计、评测闭环与迭代推进。

教育经历

清华大学 (硕士) - 生物医学工程 2024.09 - 2027.06
河北大学 (本科) - 生物技术 2020.09 - 2024.06
荣誉奖项: 全国大学生自强之星、校特等奖学金 (1%)、挑战杯国家级特等奖、中国日报社英语写作全国一等奖、“互联网+”国家级三等奖、“京津冀-粤港澳”创业大赛国家优胜奖、腾讯“2025 LIGHT 创造营”优秀项目、HICOOL 青年创业计划梦想新星奖
黑客松比赛: 2026 哈佛大学 HAIL·清华大学 VSPH 创业比赛全国一等奖、深圳黑客松高校联赛二等奖、清华大学黑客松 HACK3 一等奖

实习经历

腾讯 - 云产品六部 WorkBuddy - 技术产品 2026.04 - 2026.08
主要工作: 负责 WorkBuddy Agent 的 Harness / Context Engineering / 用户增长, 主导 PPT agent harness、工具架构与分享复用三类产品方案。
【Harness 优化】针对 ppt 渲染失败, 将 Reviewer 封装为隔离, 按需调用的 Subagent, 回传结构化 observation, 由 Main 自主决定修复策略。设置交付前置 Hook, 无复核通过记录, 系统拒绝结束任务并回灌失败原因, 加入 loop detection: 同一问题连续 2 次未修复则标记为失败, 产物通过率从 48% 提升至 71%
【Agent 工具架构重构】针对工具数量增长导致模型误调用及 Token 冗余的问题, 将其重新定义为 Harness 层的工具上下文治理问题; 主导 Tool 延迟加载与 ToolSearch 动态检索方案, 建立工具能力索引与按需注入机制, 无效 Token 占用与误调率下降 10%, 并沉淀为可扩展的多工具 Harness 编排框架。
【增长体验】0-1 拆解分享需求, 围绕产物及任务, 打造落地分享页登录授权、新域名切换、信息图转图片等, 打通“生成—分享—复用”闭环, 带动内容对外分享量与回流访问可增长 33%; 主导换肤体验从 0 搭建, 定义品牌色定制、主题变量映射等, 联动 QQ 经典主题, 建立可支撑节日/活动的主题框架, 带动 dau 增长 8%
京东科技 - 产品经理 - 白条交易 2025.12 - 2026.04
主要工作: 负责白条交易链路中产品增长与电商支付场景渗透, 0-1 打造基于 RAG 的 Agent 助手与购物车收银台优惠联动, 提升交易转化与分期收入。

【AI 挽留助手】针对免息优先付 3.64% 关闭率, 将用户关闭归因从“权益无需求”重构为“控制感丧失”与“起分门槛误解”, 并将传统强拦截升级为诊断并解决顾虑的 Agent; 主导 E-D-D (共情—诊断—化解) 多轮决策链路, 于 CoT 分步推理拆解用户顾虑识别、原因诊断与动作选择, 结合动态追问、RAG 权益召回及 Tool Calling, 接入“修改起分金额”等执行能力, 并建立 bad case 评测闭环持续优化召回与决策。上线后日均分期交易额增量超 3000 万元、日收入增量 90 万元
【购物车支付权益前置】针对白条权益仅在收银台曝光、用户决策介入过晚导致的转化流失, 主导将权益前置至购物车并贯穿结算链路; 基于购物车、结算页、收银台三阶段决策差异, 设计 6 类权益展示策略及品类/客群匹配规则, 并通过 A/B 实验验证最优方案, 横向推动支付准入、molo 智能决策与交易结算改造。上线后日均成交增量约 1 万单, 转化率 3.4%→3.7%, 沉淀“权益前置—链路承接—实验验证”的增长方法论。

月之暗面 (Kimi) - AI 产品实习生 2025.06 - 2025.09
主要工作: 负责 Deep Research Agent 的评测体系、决策策略与报告生成流程优化, 推动复杂研究任务准确率和报告稳定性提升

【评测与决策优化】引入 GAIA/xBench 与 LLM-as-a-Judge, 使用 Agentops 定位约 50% 损耗源于 Query 生成环节, 推动优化重心由答案层 Prompt 调参前移至决策链路。进一步设计面向复杂问题的分层解析模板、基于置信度的动态搜索策略及显式中间状态模块, 将在 xBench 准确率由 55% 提升至 60%。
【流程与 Prompt 优化】重构报告生成链路, 将段落生成升级为 Section 级结构化流程, 设计差异化策略以支持模块化生成与增量修改, 用户手动修正率降低 20%
【竞品对比与 LLM 评测】针对 Genspark 等竞品体验高度主观的问题, 主导建立评测指标与可复用评测案例集, 基于 LLM-as-a-Judge 多维评分, 提供量化依据。

科研经历

OScaR: The Occam's Razor for Extreme KV Cache Quantization in LLMs and Beyond (ICLR, CCF-A) 2025.12 - 2026.05
揭示 TNI 为 KV Cache 量化瓶颈, 提出基于分流旋转与全 Token 缩放的轻量级通用量化框架, 精度损失 < 0.1%, 显著降低大模型推理显存占用
Attention Sink in Transformers (arXiv:2604.10098, Computer Science Review SCI 一区) 2026.01 - 2026.04
Journal of Chromatography A (SCI 一区) 2022.03 - 2022.10

项目经历

项目经历 - 脊柱侧弯原创识别及居家康复 - 负责人 2024.12 - 2025.12
主导 0-1 产品构建, 将粗放的「拍照+识别」流程重构为「拍摄引导-质量校验-自动评估-结果解读」闭环模块, 解决用户自测姿势不规范导致的算法误判;
凭借该产品方案获得朝阳区数字疗法 50 万元孵化资金、腾讯 LIGHT 创造营优秀项目 (最高奖项)、HICOOL 创业计划梦想新星奖, 深圳黑客松联赛二等奖等
其他项目 (可在个人主页体验): 基于多智能体架构的数字分身旅游定制、基于 RAG 和知识图谱的医疗问诊助手

专业技能

产品/工具: Vibecoding (Cursor、Claude、Codex)、Figma、Axure、Adobe Photoshop、Excel、SQL、Python、C、C++
技术栈: 熟悉 Transformer、KV Cache、强化学习、微调、RAG、LangChain、Agent Harness 设计及 Context Engineering, 理解 ReAct、CoT、MCP、Memory 与 Multi-Agent 编排机制; 具备训练数据构造评测集设计及效果评估能力; 理解 LLM、VLM、VLA、World Model 等模型架构及应用范式。